

FORECASTING

SERIES DE TIEMPO

LECCIÓN 4

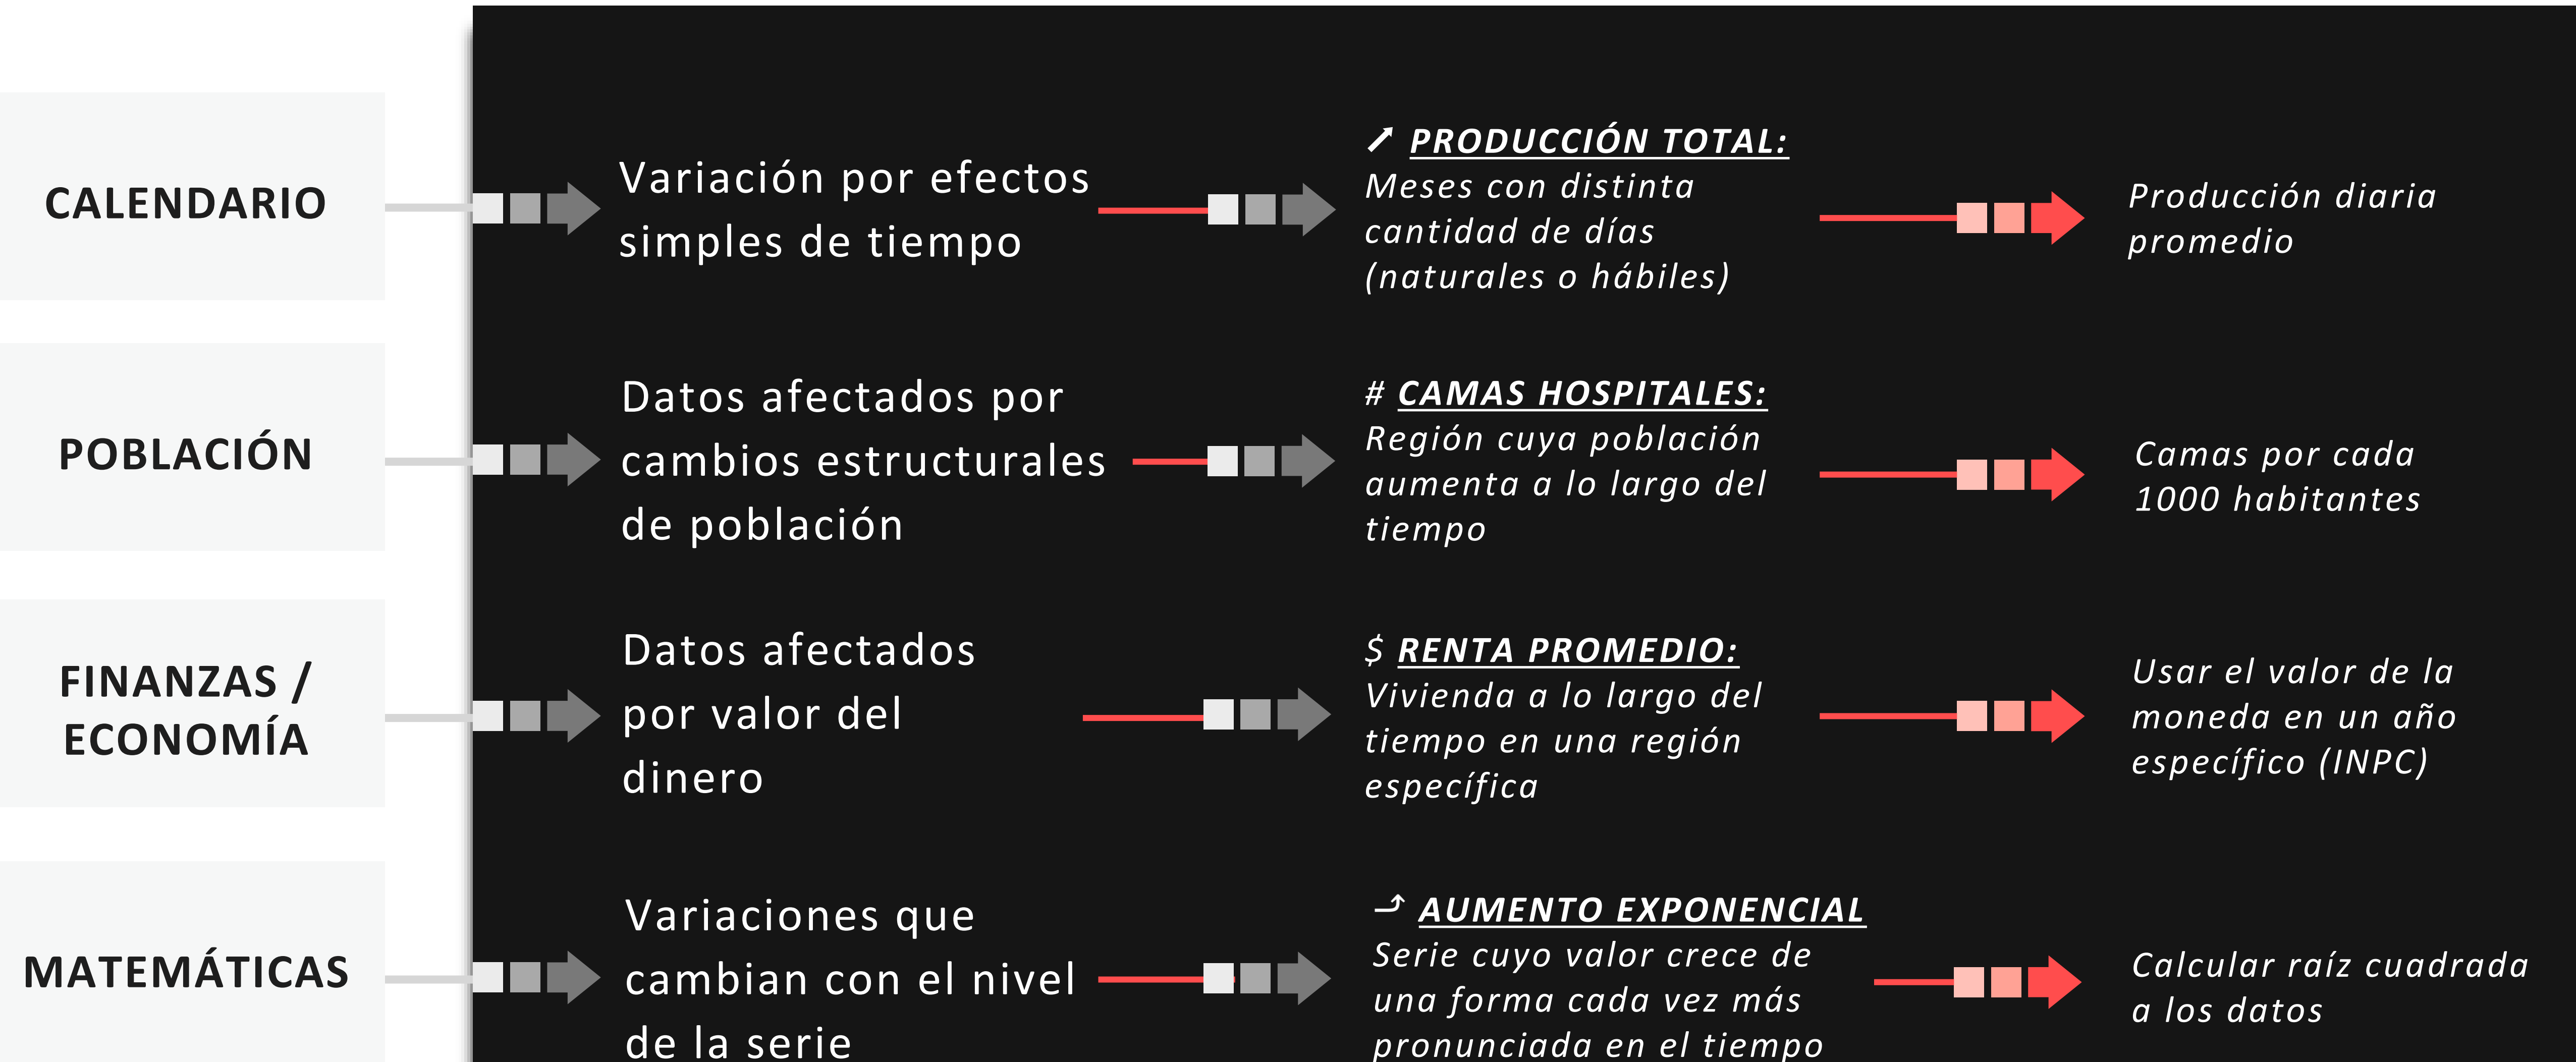
Applied Mathematics and Actuary Training



FORECASTING

Lección 4 – Transformaciones y Suavizamiento

TRANSFORMACIONES




CUIDADO!!
CON INTERPRETACIONES

CAJA DE HERRAMIENTAS DEL FORECASTER

TRANSFORMACIÓN LOGARÍTMICA

SERIE TEMPORAL
 $\{x_t\}$



TRANSFORMACIÓN
 $y_t = \log(x_t)$


INTERPRETABLE:
CAMBIOS RELATIVOS O PORCENTUALES

Sea $y = \log_{10}(x)$
 $y' = \log_{10}(x')$

con: $y' = y + 1 \Rightarrow x' = 10x$

MODELO MULTIPLICATIVO

$x_t = m'_t s'_t z'_t$




MODELO ADITIVO


$y_t = \ln(x_t)$
 $= \ln(m'_t) + \ln(s'_t) + \ln(z'_t)$
 $= m_t + s_t + z_t$

TRANSFORMA EN:

Transformación BoxCox (Auto Lambda)




SERIE
 $\{x_t\}$



BOX-COX

$y_t = \begin{cases} \ln(x_t) & \text{si } \lambda = 0 \\ \frac{x_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \end{cases}$

**TRANSFORMACIÓN
PODEROSA!**



**DEVOLVER
ESCALA
ORIGINAL**

BOX-COX INVERSA


$x_t = \begin{cases} e^{y_t} & \text{si } \lambda = 0 \\ (\lambda y_t + 1)^{1/\lambda} & \text{si } \lambda \neq 0 \end{cases}$

AJUSTE POR SESGO

$x_t = \begin{cases} e^{y_t} \left[1 + \frac{\sigma_h^2}{2} \right] & \text{si } \lambda = 0 \\ (\lambda y_t + 1)^{1/\lambda} \left[1 + \frac{\sigma_h^2 (1 - \lambda)}{2(\lambda y_t + 1)^2} \right] & \text{si } \lambda \neq 0 \end{cases}$

x_t : Serie Original a tiempo t
 y_t : Serie Transformada a tiempo t
 m_t : Tendencia en tiempo t
 s_t : Estacionalidad en tiempo t
 z_t : Error residual en tiempo t
 σ_h^2 : Varianza en predicción h pasos

SUAVIZAMIENTO EXPONENCIAL SIMPLE



MÉTODO: Estimar μ_t por medio de:

$$f_t = \alpha x_t + (1 - \alpha)f_{t-1} \quad \text{con} \quad f_1 = x_1 \quad \text{y} \quad 0 < \alpha < 1$$

f_t : Promedio Móvil Ponderado Exponencialmente

α : Parámetro de suavizamiento

$\alpha \approx 1$ Poco suavizamiento

$\alpha \approx 0$ Mucho suavizamiento

Estándar $\alpha = 0.2$

Otra forma útil de verlo es haciendo sustituciones:


Para $f_{t-1} = \alpha x_{t-1} + (1 - \alpha)f_{t-2} \Rightarrow f_t = \alpha x_t + \alpha(1 - \alpha)x_{t-1} + (1 - \alpha)^2 f_{t-2}$

Sustituyendo sucesivamente llegamos a:

$$f_t = \alpha x_t + \alpha(1 - \alpha)x_{t-1} + \alpha(1 - \alpha)^2 x_{t-2} + \alpha(1 - \alpha)^3 x_{t-3} + \dots$$

Por último podemos verlo como:

$$f_t = \alpha(x_t - f_{t-1}) + f_{t-1} \quad \text{en donde } x_t - f_{t-1} \text{ representa el error de predicción a un paso}$$



**SUAVIZAMIENTO
EXPONENCIAL**
Se queda Corto



PROMEDIO PONDERADO (PP)
*Ajustado por:
Nivel, Pendiente y Estacionalidad*

HOLT-WINTERS FORMA ESTACIONAL ADITIVA

Ecuaciones actualización x_t con periodo p

$$a_t = \alpha(x_t - s_{t-p}) + (1 - \alpha)(a_{t-1} + b_{t-1})$$

PP entre (Observación más reciente) y (Pronóstico Previo del nivel)

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

PP entre (Pendiente anterior) y (Diferencia entre niveles estimados t y $t - 1$)

$$s_t = \gamma(x_t - a_t) + (1 - \gamma)s_{t-p}$$

PP entre (Estimación Anterior de Efecto Estacional) y (Diferencia entre observación y nivel estimado)

ECUACIÓN DE PRONÓSTICO: $\hat{x}_{n+k|n} = a_n + kb_n + s_{n+k-p}$

HOLT-WINTERS FORMA ESTACIONAL MULTIPLICATIVA


Ecuaciones actualización x_t con periodo p

$$a_t = \alpha\left(\frac{x_t}{s_{t-p}}\right) + (1 - \alpha)(a_{t-1} + b_{t-1})$$

$$b_t = \beta(a_t - a_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma\left(\frac{x_t}{a_t}\right) + (1 - \gamma)s_{t-p}$$

ECUACIÓN DE PRONÓSTICO: $\hat{x}_{n+k|n} = (a_n + kb_n)s_{n+k-p}$



a_t : Nivel estimado a tiempo t ($a_1 = x_1$)
 b_t : Pendiente estimada a tiempo t
 s_t : Efecto estacional estimado a tiempo t

$\hat{x}_{n+k|n}$: Pronóstico para la serie en el tiempo $n + k$
 dado que conocemos la serie hasta tiempo n

FORECASTING

SERIES DE TIEMPO

Transformaciones y Suavizamiento | Lección 4

LECCIÓN 4