

FORECASTING SERIES DE TIEMPO

colección 5





LECCIÓN 5

FORECASTING

Lección 5 – Regresión


Applied Mathematics and Actuary Training



REGRESIÓN LINEAL EN SERIES DE TIEMPO

ESTIMAR UNA ST

$\{y_t\}$
Variable
Pronóstico
o Dependiente



RELACIÓN LINEAL

con otra serie $\{x_t\}$

Variable
Predictora
o Independiente

MODELO DE REGRESIÓN LINEAL SIMPLE

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t$$

β_0 : Intercepto (valor de y cuando $x = 0$)

β_1 : Pendiente (cambio en y cuando x aumenta una unidad)

ε_t : Error aleatorio (desviación del modelo lineal)

MODELO DE REGRESIÓN LINEAL MÚLTIPLE

$$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \cdots + \beta_k x_{k,t} + \varepsilon_t$$

x_1, \dots, x_k son las k variables predictoras

β_1, \dots, β_k : Efecto marginal de c/predictor

ε_t : Error aleatorio

SUPOSICIONES:

- La relación planteada por el modelo es verdadera
- Los predictores $\{x_{k,t}\}$ no son variables aleatorias
- Los errores $\{\varepsilon_t\}$:
 - Tienen media 0
 - No están autocorrelacionados
 - No tienen correlación con los predictores


TENDENCIA

Utilizamos:

$$x_{1,t} = t \quad \text{para modelar}$$

Es decir, $y_t = \beta_0 + \beta_1 t + \varepsilon_t$

Es posible utilizar potencias:
 $y_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \varepsilon_t$



PREDICTORES IMPORTANTES REGRESIÓN DE ST

ESTACIONALIDAD

Variable categórica, se crean variables dummy:

Ejemplo trimestral

| | $s_{1,t}$ | $s_{2,t}$ | $s_{3,t}$ |
|-------|-----------|-----------|-----------|
| Trim1 | 1 | 0 | 0 |
| Trim2 | 0 | 1 | 0 |
| Trim3 | 0 | 0 | 1 |
| Trim4 | 0 | 0 | 0 |

Y modelamos:

$$y_t = \beta_0 + \beta_1 s_{1,t} + \beta_2 s_{2,t} + \beta_3 s_{3,t} + \varepsilon_t$$

¡Podemos incluir ambas!

$$y_t = \beta_0 + \beta_1 s_{1,t} + \beta_2 s_{2,t} + \beta_3 s_{3,t} + \beta_4 t + \varepsilon_t$$

BONDAD DE AJUSTE

Múltiples Predictores
 $\{x_{1,t}\} \dots \{x_{k,t}\}$

Seleccionar los mejores

Métricas de precisión predictiva

| R^2 | R^2 Ajustada | AIC | BIC |
|--|---|---|---|
| <p>Coeficiente de Determinación</p> $R^2 = \frac{\sum(\hat{y}_t - \bar{y})^2}{\sum(y_t - \bar{y})^2}$ | <p>Coeficiente de Determinación Ajustado</p> $R_a^2 = 1 - \frac{T-1}{T-k-1}(1-R^2)$ | <p>Criterio de información de Akaike</p> $AIC = 2(k-1) - 2\ln(L_k)$ | <p>Criterio de información Bayesiano</p> $BIC = \ln(L_k)(k-1) - 2\ln(L_k)$ |
| <p>Proporción de variación en variable pronóstico y_t explicada por la regresión</p> | <p>R^2 incrementa agregando predictores (incluso insignificantes) R_a^2 compensa</p> | <p>Penaliza por el número de parámetros k utilizado para el modelo</p> | <p>Penaliza más fuertemente el número de parámetros k utilizado para el modelo</p> |

$$0 \leq R^2 \leq 1$$

Entre más grande mejor

$$0 \leq R_a^2 \leq 1$$

Entre más grande mejor

Con pocos datos tiende a preferir más predictores
Entre más pequeño mejor

Es más estricto con el sobreajuste en datasets grandes
Entre más pequeño mejor

T : Número de datos conocidos de la ST
 k : Número de predictores del modelo
 L_k : Logverosimilitud maximizada



ANÁLISIS DE RESIDUALES

REMANENTE TRAS AJUSTAR UN MODELO

$$e_t = y_t - \hat{y}_t$$

BUSCAMOS

VERIFICAMOS

ALEATORIEDAD

Si existen patrones que nos indiquen lo contrario

MEDIA EN 0

Si oscilan arriba y abajo de 0
(entre más pequeños mejor)


NO AUTOCORRELACIÓN

Si presentan correlación serial

Son una Serie de Tiempo

Si el modelo es correcto.

Muestra de los errores aleatorios ε_t



PRUEBAS FORMALES

$H_0: \text{no hay autocorrelación}$ VS $H_1: \text{hay autocorrelación}$

Ljung-Box

$$Q = n(n + 2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n - k}$$

$Q \sim \chi_h^2$

Breusch-Godfrey

$$nR^2 \sim \chi_p^2$$

h : número de lags que se prueban

$\hat{\rho}_k^2$: Autocorrelación de la muestra

p : Número de lags de errores (regresión aux)

R^2 : Coef de determinación (regresión aux)



FORECASTING SERIES DE TIEMPO

Regresión | Lección 5

