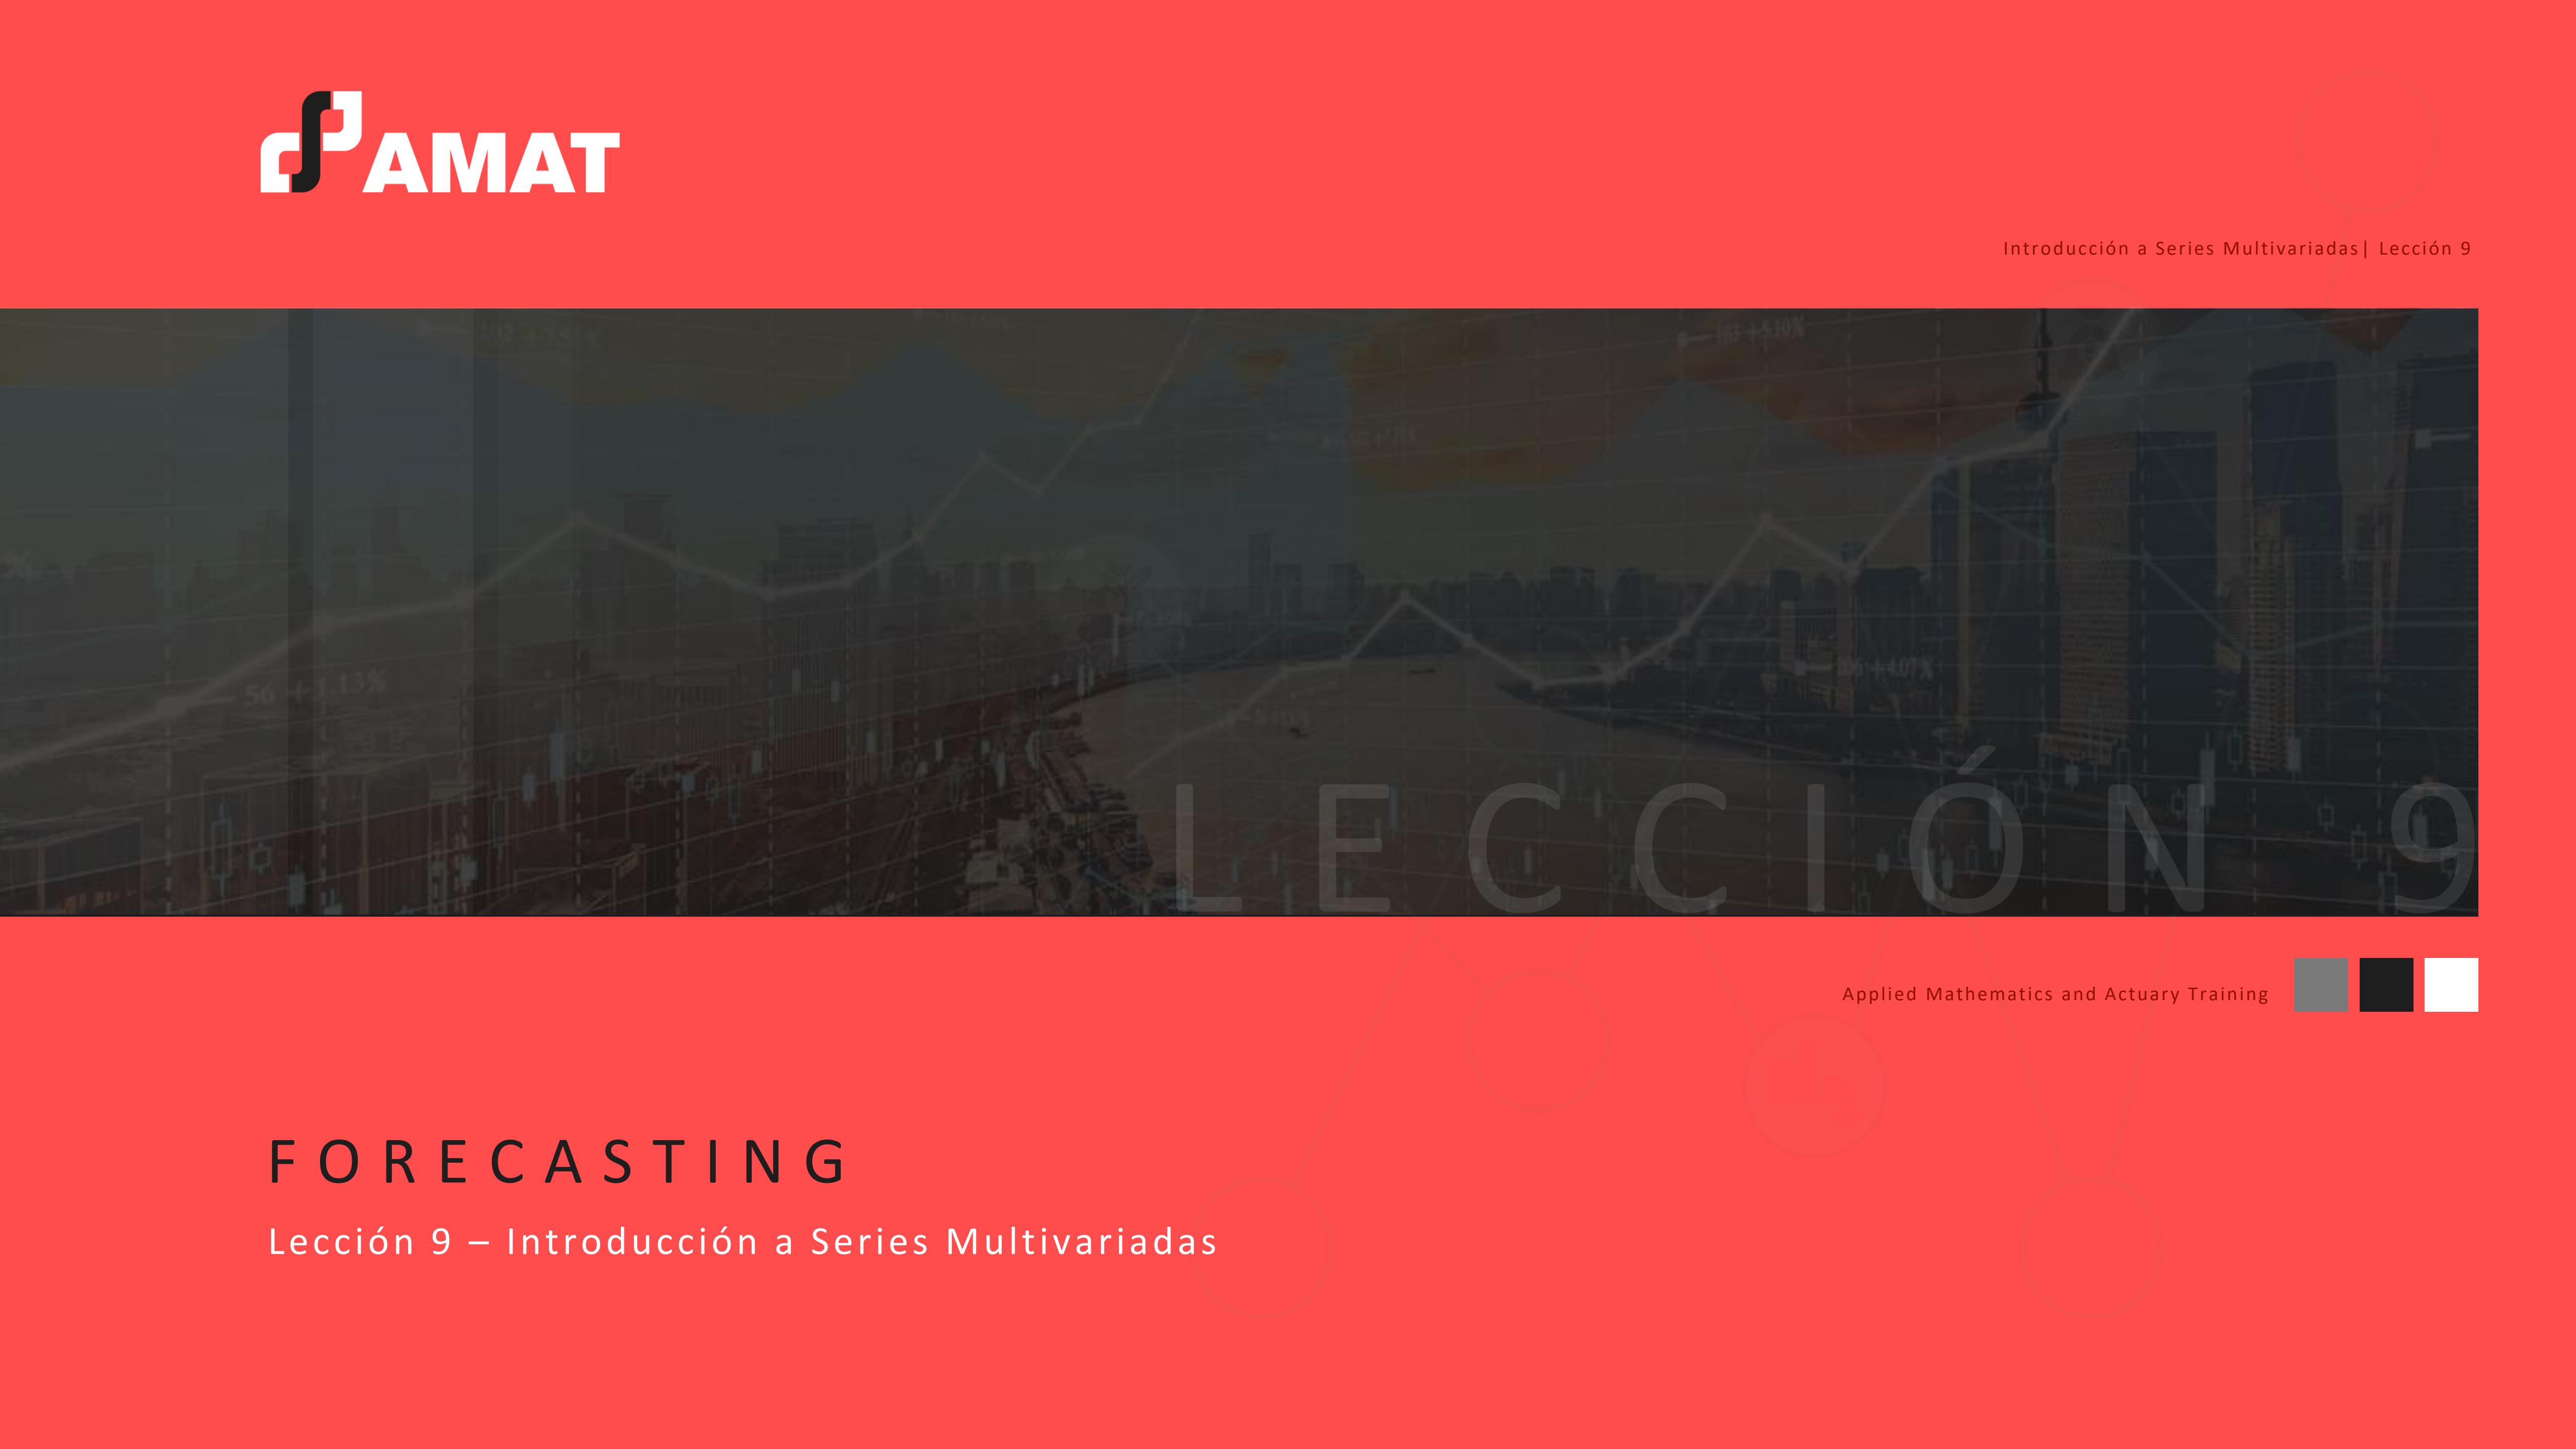


FORECASTING SERIES DE TIEMPO

LECCIÓN 9





LECCIÓN 9

FORECASTING

Lección 9 – Introducción a Series Multivariadas

Applied Mathematics and Actuary Training



CAUSALIDAD DE GRANGER

Imaginemos un modelo de regresión

$$y_t = \beta_0 + \beta_1 x_t + \epsilon_t$$

y_t es la variable dependiente/pronosticada

x_t es la variable independiente/explanativa

Suena razonable decir que x causa a y

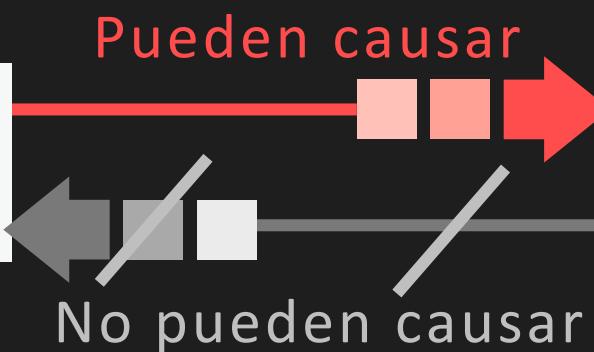
Sin embargo, la **causalidad** puede ir en cualquier dirección, o en ambas, o en ninguna

En series de tiempo

Podemos aprovechar que

El tiempo no corre hacia atrás

Eventos Pasados



Eventos Futuros

Causalidad de Granger solo es relevante en series de tiempo

En el sentido de Granger
 x causa a y

Si valores pasados de x
Ayudan a explicar a y

Esto no garantiza que x causa a y
Pero sugiere al menos que x podría estar causando a y

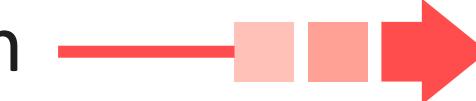
Por ejemplo, sean dos series estacionarias $\{x_t\}$; $\{y_t\}$ que pueden ser modeladas como:

$$y_t = \phi_1 + \alpha_1 y_{t-1} + \cdots + \alpha_p y_{t-p} + \beta x_{t-1} + \cdots + \beta_q x_{t-q} + \epsilon_t$$

$\{x_t\}$ causa a $\{y_t\}$ en el sentido de Granger si algún coeficiente $\beta_i \neq 0$

MODELOS ESTOCÁSTICOS

MODELOS VAR

Si queremos
comprobar la dirección 
de la causalidad

Modelo Vectorial
Autorregresivo
VAR

- Estas dos ecuaciones conforman un modelo VAR:

$$y_t = \phi_1 + \alpha_{11}y_{t-1} + \cdots + \alpha_{1p}y_{t-p} + \beta_{11}x_{t-1} + \cdots + \beta_{1q}x_{t-q} + \epsilon_{1t}$$

$$x_t = \phi_1 + \alpha_{21}y_{t-1} + \cdots + \alpha_{2p}y_{t-p} + \beta_{21}x_{t-1} + \cdots + \beta_{2q}x_{t-q} + \epsilon_{2t}$$

- La primera prueba si **X causa a Y en el sentido de Granger**
- La segunda si **Y causa a X en el sentido de Granger.**

NOTA: Los coeficientes tienen subíndices que indican en qué ecuación se encuentran

Variables VAR deben ser estacionarias.

Si hay raíces unitarias, se toman diferencias
y que el modelo incluya los cambios

El modelo VAR
puede extenderse a
Múltiples Variables

ESTABILIDAD DEL MODELO

ESTACIONARIEDAD

- Consideremos el modelo VAR:

$$y_t = 0.3y_{t-1} + 0.8x_{t-1} + \epsilon_{1t}$$

$$x_t = 0.9y_{t-1} + 0.4x_{t-1} + \epsilon_{2t}$$

- Podemos verlo de forma matricial como:

$$\begin{bmatrix} y_t \\ x_t \end{bmatrix} = \begin{bmatrix} 0.3 & 0.8 \\ 0.9 & 0.4 \end{bmatrix} \begin{bmatrix} y_{t-1} \\ x_{t-1} \end{bmatrix} + \begin{bmatrix} \epsilon_{1t} \\ \epsilon_{2t} \end{bmatrix}$$

- El modelo VAR será estacionario/estable si los eigenvalores λ de la matriz de coeficientes son menores a 1

Para calcular los eigenvalores requerimos el determinante de:

$$\begin{vmatrix} 0.3 - \lambda & 0.8 \\ 0.9 & 0.4 - \lambda \end{vmatrix} = (0.3 - \lambda)(0.4 - \lambda) - (0.9)(0.8)$$

$$= 0.12 - 0.3\lambda - 0.4\lambda + \lambda^2 - 0.72$$

$$= \lambda^2 - 0.7\lambda - 0.6$$

Chicharrón:

$$\lambda_1 = \frac{-(-0.7) + \sqrt{(0.7)^2 - 4(1)(-0.6)}}{2(1)} = 1.2$$

$$\lambda_2 = \frac{-(-0.7) - \sqrt{(0.7)^2 - 4(1)(-0.6)}}{2(1)} = -0.5$$

Debido a que $\lambda_1 > 1$ este sistema VAR no es estacionario

FORECASTING SERIES DE TIEMPO

Introducción a Series Multivariadas | Lección 9

